

Spis treści

1.	Wprowadzenie i kontekst problemu	2
2.	Cel analizy i pytania decyzyjne.....	2
3.	Opis case study i założeń	2
4.	Data lakehouse i Databricks.....	4
5.	Tworzenie volume.....	6
6.	Przetwarzanie danych nieustrukturyzowanych.....	8
6.1.	Warstwa Bronze	8
6.1.1.	Dane nieustrukturyzowane.....	8
6.1.2.	Dane ustrukturyzowane	9
6.2.	Warstwa Silver.....	9
6.2.1.	Dane nieustrukturyzowane.....	9
6.2.2.	Dane ustrukturyzowane	10
6.3.	Warstwa Gold.....	10
6.3.1.	Dane nieustrukturyzowane.....	10
6.3.2.	Dane ustrukturyzowane	11
8.	Wizualizacje.....	14
9.	Modelowanie predykcyjne ML.....	16
9.1.	Zmienne modelu	16
9.2.	Model	17
10.	Wrażliwość danych fakturowych	18
11.	Podsumowanie i wnioski	19

1. Wprowadzenie i kontekst problemu

Data lakehouse to architektura zarządzania danymi, która łączy skalowalność i niski koszt przechowywania (data lake) z wydajnością, strukturą oraz mechanizmami zarządzania hurtowni danych. W biznesie służy jako „źródło prawdy” można go użyć zarówno do prowadzenia analityki biznesowej (BI) oraz zaawansowanych projektów uczenia maszynowego (ML)

2. Cel analizy i pytania decyzyjne

Celem projektu jest sprawdzenie możliwości architektury Data Lakehouse w zakresie przetwarzania różnych typów danych oraz przetestowanie środowiska Databricks jako platformy do budowy pipeline'ów danych i analiz biznesowych. Oraz odpowiedzi na pytania:

- Kim są najcenniejsi klienci?
- Jaka będzie wartość przyszłych zakupów klienta?
- Jaki procent całkowitego przychodu generuje dany segment klientów?

3. Opis case study i założeń

Operacje zostały przeprowadzone w platformie Databricks, która umożliwia zespołom zajmującym się danymi wspólną pracę nad zasobami przechowywanymi w architekturze typu Lakehouse.

Wykorzystane dane pochodziły z repozytorium <https://github.com/microsoft/sql-server-samples/tree/master/samples/databases/northwind-pubs>.




Fig. 1 Oryginalna architektura OLTP.

Rekordy dotyczące sprzedaży, które zostały wyeksportowane do plików w formacie .csv z DBMS.

4. Data lakehouse i Databricks

Lakehouse w przeciwieństwie do data warehouse przechowuje wszechstronne typy danych (zarówno ustrukturyzowane, jak i nieustrukturyzowane np. pliki wideo, obrazy, logi).

Tabela 1 Porównanie architektury Data Warehouse i Lakehouse.

Cecha	Data Warehouse	Lakehouse
Podejście do schematu	Schema-on-write	Hybrydowe
Typy danych	Tylko ustrukturyzowane	Wszystkie typy
Zastosowanie	Raportowanie BI	BI, ML, AI, Streaming
Zasoby	Zazwyczaj połączone	W pełni odseparowane i skalowalne
Efektywność kosztowa	Niska (wysoki koszt skali)	Zoptymalizowana

Architektura Lakehouse opiera się na kilku elementach:

- **Transakcje ACID:** zapewniają spójność i bezpieczeństwo danych.
- **Zarządzanie schematem danych:** system kontroluje strukturę danych.
- **Oddzielenie pamięci od mocy obliczeniowej:** dane mogą być przechowywane niezależnie od zasobów obliczeniowych.
- **Obsługa otwartych formatów danych.**

Pipeline przetwarzania danych w architekturze data lakehouse opiera się na architekturze medalionu, która dzieli proces na logiczne warstwy.




Fig. 2 Schemat przetwarzania danych w Data Lakehouse.

Tabela 2 Porównanie warstw.

Warstwa	Opis	Charakterystyka / Procesy	Główna rola
Bronze (Dane surowe)	Oryginalne dane stanowiące historyczny zapis wszystkiego, co wpłynęło do systemu.	Dane są przechowywane w surowej postaci bez większych modyfikacji.	Umożliwia ponowne przetwarzanie danych w przypadku błędów w dalszych etapach pipeline'u.
Silver (Dane oczyszczone i ustrukturyzowane)	Dane z warstwy Bronze przefiltrowane, oczyszczone i dopasowane do odpowiednich schematów.	Usuwanie duplikatów, standaryzacja formatów dat, łączenie tabel z różnych systemów w spójne widoki.	Stanowi „jedyne źródło prawdy” dla analityków danych i inżynierów ML, zapewniając dane wysokiej jakości.
Gold (Dane biznesowe / zagregowane)	Najwyższy poziom przetworzenia danych przygotowany pod potrzeby biznesowe.	Agregacja danych, obliczanie KPI, przygotowanie tabel do raportowania w Power BI lub Tableau. Tworzenie feature tables dla AI/ML.	Wspiera raportowanie biznesowe, dashboards BI oraz trenowanie modeli sztucznej inteligencji i uczenia maszynowego.

Databricks to narzędzie przeznaczone dla analityków danych, inżynierów danych oraz specjalistów ds. uczenia maszynowego, oferujące narzędzia do budowy pipeline'ów ETL, analizy biznesowej (BI) oraz rozwijania modeli sztucznej inteligencji. Użytkownicy korzystają z interaktywnych notatników (notebooks), pozwalających na wspólne pisanie kodu w różnych językach np. Python czy SQL, a także na automatyzację procesów i zarządzanie klastrami obliczeniowymi. Na potrzeby niniejszego projektu wykorzystano bezpłatną wersję platformy – Databricks Free Edition, dostępną pod adresem community.cloud.databricks.com.

5. Tworzenie volume

W projekcie używany był katalog bi, schematu default oraz Volume bi.




Fig. 3 Tworzenie nowego volume - 1.




Fig. 4 Tworzenie nowego volume - 2.




Fig. 5 Załadowanie zasobu do volume -1.




Fig.6 Załadowanie zasobu do volume -2.

Po wgraniu pliki będą dostępne pod ścieżką:

/Volumes/bi/default/bi/

6. Przetwarzanie danych nieustrukturyzowanych

Na potrzeby projektu wygenerowana została przy użyciu narzędzi sztucznej inteligencji przykładowa faktura VAT w formacie PDF a następnie była załadowana do wcześniej stworzonego volume.

FAKTURA VAT NR FV/05/2026/001

Sprzedawca

Firma XYZ Sp. z o.o.
ul. Przykładowa 12
30-001 Kraków
NIP: 945-123-45-67
Telefon: +48 600 123 456
E-mail: kontakt@firmaxyz.pl

Nabywca

ABC Solutions Sp. z o.o.
ul. Biznesowa 45
00-950 Warszawa
NIP: 525-987-65-43

Data wystawienia: 07.05.2026

Data sprzedaży: 07.05.2026

Forma płatności: Przelew

Termin płatności: 14 dni

Numer rachunku: 12 3456 7890 1234 5678 9012 3456

Lp.	Nazwa usługi	Ilość	Cena netto	VAT	Wartość netto	Wartość brutto
1	Usługa analizy danych i przygotowania dashboardu Power BI	1	2 500,00 zł	23%	2 500,00 zł	3 075,00 zł

Podsumowanie

- Wartość netto: 2 500,00 zł
- VAT 23%: 575,00 zł
- Do zapłaty brutto: **3 075,00 zł**

Uwagi

Dziękujemy za skorzystanie z naszych usług.

Fig. 7 Przykładowa faktura

6.1. Warstwa Bronze

6.1.1. Dane nieustrukturyzowane

Plik PDF został odczytany przy użyciu formatu binaryFile w Apache Spark, zwracając zawartość pliku jako tablicę bajtów wraz z metadanymi.

Do ekstrakcji treści z dokumentu PDF wykorzystana została funkcja ai_parse_document.

Funkcja ta należy do rodziny AI Functions - wbudowanych funkcji SQL/PySpark

korzystających z modeli językowych i wizyjnych. Funkcja ai_parse_document przyjmuje treść dokumentu jako tablicę bajtów i zwraca ustrukturyzowany obiekt JSON zawierający wykryte elementy dokumentu z ich typami, współrzędnymi bounding box, poziomem pewności oraz treścią. Zawartość JSON została spłaszczona a wynik zapisany jako tabelę Delta w warstwie Bronze.

6.1.2. Dane ustrukturyzowane

Pliki CSV zostały odczytane przy użyciu Apache Spark z wykorzystaniem opcji automatycznego rozpoznawania schematu a każda tabela została zapisana oddzielnie w formacie Delta Lake w katalogu bi.bronze.

Do warstwy Bronze załadowano między innymi następujące dane:

- orders
- order_details
- customers
- products
- categories
- suppliers

6.2. Warstwa Silver

6.2.1. Dane nieustrukturyzowane

Do wyodrębnienia konkretnych pól z tekstu faktury zastosowana została funkcja `regexp_extract`: wyrażenia dopasowywały wzorce charakterystyczne dla polskich faktur VAT:

Tabela 3 Wyekstrahowane dane.

Kolumna	Wyekstrahowana wartość
invoice_number	FV/05/2026/001
seller_name	Firma XYZ Sp. z o.o.
buyer_name	ABC Solutions Sp. z o.o.
issue_date	07.05.2026
payment_method	Przelew
gross_total	3 075,00
load_timestamp	2026-05-07T18:12:50.151Z

Dane Silver zorganizowano w trzy osobne tabele odpowiadające encjom biznesowym:

- **silver_transactions:** dane transakcyjne (numer faktury, data, kwota brutto, ścieżka pliku)
- **silver_customers:** unikalni nabywcy wydobyti z faktur, usunięcie duplikatów przez `dropDuplicates()`
- **silver_products:** nazwy usług i produktów z faktur

6.2.2. Dane ustrukturyzowane

Usunięte zostały rekordy zawierające brakujące oraz zduplikowane rekordy funkcją. Zastosowany został filtr logiki biznesowej:

- zamówienia z ilością produktów mniejszą lub równą zero,
- rekordy z błędnymi wartościami sprzedaży.

Następnie została wykonana agregacja w celu stworzenia tabeli zdenormalizowanej. W wyniku utworzony został widok analityczny zawierający dane transakcyjne oraz biznesowe. Ponadto dodane zostały nowe cechy m. in.:

- net_revenue: rzeczywista wartość sprzedaży po uwzględnieniu rabatu,
- customer_country: kraj klienta,
- category_name: nazwa kategorii produktu,
- supplier_name: nazwa dostawcy,
- discount_value: wartość rabatu,
- daty pomocnicze umożliwiające późniejszą analizę czasową.

Warstwa Silver to tzw. jedyne źródło prawdy.

6.3. Warstwa Gold

6.3.1. Dane nieustrukturyzowane

Zostały stworzone trzy tabele Gold:

- **gold_invoice_summary:** zestawienie faktur z podstawowymi polami:

```
df_gold_sales = df_trans.select("invoice_number", "issue_date", "gross_amount", "source_file")
df_gold_sales.write.mode("overwrite").format("delta").saveAsTable("bi.default.gold_invoice_summary")
```

- **gold_kpi_summary:** zagregowane wskaźniki KPI:

```
df_gold_kpi = df_trans.agg(
    count("invoice_number").alias("total_invoices"),
    sum("gross_amount").alias("total_gross_amount_pln")
)
df_gold_kpi.write.mode("overwrite").format("delta").saveAsTable("bi.default.gold_kpi_summary")
```

- **gold_customer_transactions:** zestawienie transakcji z danymi klienta:

```
df_gold_by_customer = df_trans.join(df_cust, "customer_key") \
    .select("customer_name", "invoice_number", "gross_amount", "issue_date")
df_gold_by_customer.write.mode("overwrite").format("delta").saveAsTable("bi.default.gold_customer_transactions")
```

6.3.2. Dane ustrukturyzowane

Na podstawie danych Silver utworzony został zestaw danych przedstawiający:

- sprzedaż według kraju klienta,
- sprzedaż według kategorii produktów,
- sprzedaż w podziale miesięcznym,
- średnią wartość zamówienia,
- liczbę zamówień,
- łączny przychód.

7. Automatyzacja

Po zbudowaniu notebooków Bronze, Silver, Gold proces został zautomatyzowany w celu uniknięcia ręcznego uruchamiania każdego notebooka z osobna. W tym celu wykorzystano Databricks Jobs, jest to sekwencja zadań (tasks), gdzie każde zadanie (notebook, skrypt Python/ SQL etc.) jest wykonywane w zdefiniowanej kolejności. Następne uruchamia się dopiero po pomyślnym zakończeniu poprzedniego dzięki czemu Gold nigdy nie zostanie nadpisane nieoczyszczonymi danymi z Bronze.




Fig. 8 Znalezienie Zakładki Jobs & Pipelines.




Fig. 9 Stworzenie nowego joba.




Fig. 10 Wykonany proces.

8. Wizualizacje

W warstwie Gold przygotowane zostały analizy klientów pod kątem wartości generowanego przychodu. W tym celu wykorzystano tabelę `bi.silver.orders_denormalized`, która zawierała już oczyszczone i połączone dane sprzedażowe z warstwy Silver.

Dane zostały zagregowane na poziomie klienta, z uwzględnieniem identyfikatora klienta, nazwy firmy, kraju oraz miasta. Dla każdego klienta obliczono następujące wskaźniki:

- **total_revenue:** całkowity przychód wygenerowany przez klienta,
- **total_orders:** liczba złożonych zamówień,
- **avg_order_value:** średnia wartość zamówienia,
- **last_order_date:** data ostatniego zamówienia,
- **revenue_rank:** pozycja klienta w rankingu według wartości przychodu.

Na podstawie wartości `total_revenue` utworzono ranking klientów. Pozwoliło to odpowiedzieć na pytanie: **kim są najcenniejsi klienci?** Największy przychód wygenerowali klienci QUICK, ERNSH oraz SAVEA




Fig. 11 Ranking klientów wg przychodów.

Następnie wykonano segmentację klientów na podstawie całkowitej wartości przychodu. Klientów podzielono na trzy grupy:

- **High Value:** klienci z przychodem co najmniej 10 000,
- **Medium Value:** klienci z przychodem od 4 000 do 9 999,
- **Low Value:** klienci z przychodem poniżej 4 000.

Na podstawie wykresu kołowego można zauważyć, że największą część przychodu generuje segment High Value, odpowiadający za 42,70% całkowitej sprzedaży. Segment Low Value odpowiada za 31,46% przychodu, natomiast segment Medium Value za 25,84%.




Fig. 12 Segment a suma przychodu.

Oznacza to, że grupa klientów o najwyższej wartości odpowiada za największą część przychodów firmy. Z biznesowego punktu widzenia segment High Value powinien być objęty szczególną obsługą w celu zatrzymania klienta. Segment Medium Value może stanowić grupę klientów z potencjałem wzrostu.

9. Modelowanie predykcyjne ML

Celem tej części projektu było zastosowanie uczenia maszynowego do odpowiedzi na pytanie biznesowe: który klient najprawdopodobniej złoży kolejne zamówienie w ciągu najbliższych 30 dni? Użyta została klasyfikacja binarna: dla każdego klienta model przypisuje wartość 1 (przewidywany powrót) lub 0 (brak powrotu).

Model uczono na danych z warstwy Gold, która zawiera już przetworzone, zdeduplikowane i zagregowane dane.

9.1. Zmienne modelu

Przyjęte zostało okno predykcji równe 30 dni, klient jest oznaczony jako willbuyagain = 1, jeśli jego ostatnie zamówienie zostało złożone nie wcześniej niż 30 dni przed maksymalną datą w zbiorze (1998-05-06). W przeciwnym wypadku otrzymuje wartość 0.

```
PREDICTION_WINDOW = 30
maxorderdate = gold.agg(spark_max("lastorderdate")).collect()[0][0]

df = goldfixed.withColumn(
    "willbuyagain",
    when(col("dayssincelastorderfixed") <= PREDICTION_WINDOW, 1).otherwise(0)
)
```

Rozkład w zbiorze:

Tabela 4 Rozkład cechy w zbiorze.

Klasa	Liczba klientów
willbuyagain = 1 (powróci)	54
willbuyagain = 0 (nie powróci)	35

Wybranych zostało 8 cech numerycznych opisujących zachowanie zakupowe każdego klienta:

Tabela 5 Cechy modelu.

Cecha	Opis
totalrevenue	Łączny przychód wygenerowany przez klienta
totalorders	Całkowita liczba zamówień
avgordervalue	Średnia wartość jednego zamówienia
uniqueproducts	Liczba unikalnych produktów zakupionych
uniquecategories	Liczba unikalnych kategorii produktów
avgfreight	Średni koszt frachtu na zamówienie
customerlifetimedays	Czas od pierwszego do ostatniego zamówienia (dni)
estimatedclv	Szacowana wartość klienta w cyklu życia (CLV)

Dodatkowo kolumna customersegment została zakodowana numerycznie. Wszystkie cechy zostały znormalizowane w celu uniknięcia faworyzacji cech o dużych wartościach.

9.2. Model

Do klasyfikacji zastosowana została regresja logistyczna wynikało to m. in. z ograniczeń obliczeniowych bezpłatnej wersji platformy Databricks. Dane podzielono w proporcji 75% trening i 25% test przy zapewnieniu proporcjonalności klas w obu zbiorach.

Model uzyskał na zbiorze testowym następujące wyniki:

Tabela 6 Wyniki modelu.

Metryka	Wartość	Interpretacja
Accuracy	0.4783	47,83% poprawnie sklasyfikowanych klientów
F1-Score	0.5385	Balans pomiędzy precyzją a czułością
Precision	0.5833	Spośród klientów oznaczonych jako „powracających”, 58,33% faktycznie wróciło
Recall	0.5000	Model wykrył 50% rzeczywiście powracających klientów
AUC-ROC	0.4603	Zdolność do rozróżniania klas na poziomie zbliżonym do losowego

Po wytrenowaniu modelu zastosowano go do wszystkich klientów, generując tabelę bi.gold.customerpurchasepredictions z kolumnami predictedbuy i buyprobability. Przykładowe wyniki:

Tabela 7 Przykładowe wyniki regresji.

Klient	Kraj	Segment	Liczba zamówień	Prawdopodobieństwo powrotu
QUICK-Stop	GERMANY	High Value	86	0.9999
Ernst Handel	AUSTRIA	High Value	102	0.9999
Save-a-lot Markets	USA	High Value	116	0.9998
Rattlesnake Canyon Grocery	USA	High Value	71	0.9941

Hungry Owl All-Night Grocers	IRELAND	High Value	55	0.9968
Centro comercial Moctezuma	MEXICO	Low Value	2	0.0068
Pericles Comidas clásicas	MEXICO	Medium Value	14	0.0156

Tabela bi.gold.customerpurchasepredictions posłużyła do obliczenia średniego prawdopodobieństwa powrotu wg segmentu:

Tabela 8 Średnie prawdopodobieństwo powrotu klienta wg jego segmentu.

Segment	Liczba klientów	Śr. Prawd. powrotu	Śr. Przychód [\$]
High Value	38	0.821	27 866
Medium Value	23	0.432	6 411
Low Value	28	0.402	2 122

10. Wrażliwość danych fakturowych

Faktury zawierają dane wrażliwe: numery NIP, numery rachunków bankowych, adresy, dane kontrahentów oraz szczegóły transakcji. Przetwarzanie takich informacji wymusza przestrzeganie zgodności z RODO oraz wewnętrznymi politykami bezpieczeństwa organizacji.

Funkcja ai_parse_document przesyła treść dokumentu do modelu VLM (Vision Language Model) zarządzanego przez Databricks. Kluczowe kwestie bezpieczeństwa:

- **Przesyłanie danych do modelu AI:** Zawartość faktury, włącznie z danymi osobowymi i finansowymi, jest przekazywana do modelu językowego. Przed użyciem należy zweryfikować, czy platforma przetwarza dane w ramach tej samej chmury.
- **Kontrola dostępu do Volume:** Dostęp do /Volumes/bi/default/bi powinien być ograniczony przez uprawnienia.
- **Kontrola dostępu do tabel:** Tabele powinny mieć nadane uprawnienia tylko dla uprawnionych ról.

W środowisku biznesowym konieczne może być zastosowanie dedykowanych narzędzi do przetwarzania danych nieustrukturyzowanych.

11. Podsumowanie i wnioski

Trójwarstwowa architektura (Bronze-Silver-Gold) stanowi utrzymuje przejrzystość przepływu danych w środowisku analitycznym. Kluczową zaletą tego podziału jest możliwość powrotu do każdego etapu przetwarzania. Ważnym elementem projektu było zautomatyzowanie procesu przetwarzania danych poprzez Databricks Jobs. Notebooki mogą być uruchamiane w sekwencji we wcześniej zaplanowanych zadaniach bez konieczności ręcznej ingerencji człowieka. Każda część organizacji ma dostęp do tych samych danych (warstwa Gold) a dzięki automatyzacji są one zawsze aktualne.