

Spis treści

1.	Wprowadzenie i kontekst problemu	2
2.	Cel analizy i pytania decyzyjne.....	2
3.	Sprzedaż.....	3
3.1.	Opis case study i założeń	3
3.2.	Transformacja Danych w Power Query	3
3.3.	Miary Dax.....	7
3.4.	Model danych.....	11
3.5.	Dashboard 1: <i>Sales Overview</i>	12
3.6.	Dashboard 2: <i>Monthly Performance</i>	18
3.7.	Dashboard 3: <i>Customer Analysis</i>	22
3.8.	Testowanie i optymalizacja dashboardów.....	26
4.	Kolizje drogowe	28
4.1.	Opis case study i założeń	28
4.2.	Pozyskanie danych	28
4.3.	Eksploracyjna Analiza Danych i Tworzenie Cech	29
4.3.1.	Braki Danych Przegląd.....	29
4.3.2.	Imputacja braków dzielnic metodą przestrzenną.....	30
4.3.3.	Transformacja i czyszczenie zbioru danych	32
4.3.4.	Feature Engineering: Python	32
4.3.5.	Feature Engineering: DAX	35
4.3.6.	Ujednolicenie nazw ulic w Power Query.....	36
4.3.7.	Wizualizacje eksploracyjne i mapa hotspotów	37
4.4.	Dashboard 1: <i>New York City Collision & Fatality Analysis</i>	39
4.5.	Dashboard 2: <i>New York City Hotspots & Spatial Analysis</i>	44
4.6.	Wnioski z analizy kolizji drogowych w Nowym Jorku.....	49
5.	Podsumowanie	49

1. Wprowadzenie i kontekst problemu

W dobie generacji oraz przepływu ogromnych wolumenów danych operacyjnych, konieczne jest użycie odpowiednich narzędzi analitycznych w celu ukazania danych w sposób umożliwiający interpretację oraz wykorzystanie danych w procesach decyzyjnych.

W projekcie zostały zbudowane interaktywne dashboardy w programie Microsoft Power BI, obejmujące dwa odrębne obszary tematyczne: analizę sprzedaży oraz analizę kolizji drogowych na terenie Nowego Jorku.

W przypadku dashboardów sprzedażowych dane zostały zasymulowane i obejmują informacje o transakcjach, produktach, klientach oraz wynikach finansowych firmy. Projekt sprzedażowy składa się z trzech dashboardów: **Sales Overview**, **Monthly Performance** oraz **Customer Analysis**, które razem tworzą obraz działalności handlowej. Dashboardy dotyczące kolizji zostały zbudowane w oparciu o rzeczywisty, publiczny zbiór danych udostępniony przez miasto Nowy Jork Motor Vehicle Collisions - Crashes, zawierający informacje o wypadkach drogowych, ich lokalizacji, czasie wystąpienia oraz przyczynach. Projekt kolizyjny składa się z dwóch dashboardów: **Collision & Fatality Analysis** oraz **Hotspots & Spatial Analysis**.

2. Cel analizy i pytania decyzyjne

Głównym celem projektu było dostarczenie odbiorcom biznesowym i analitycznym narzędzia umożliwiającego wgląd w kluczowe wskaźniki efektywności (KPIs) oraz identyfikację istotnych wzorców w danych. Dashboardy ukazują zarówno analizę ogólną, jak i szczegółową.

W obszarze sprzedaży wizualizacje mają odpowiadać na pytania:

- Jakie są trendy sprzedaży i zysku w ujęciu miesięcznym, kwartalnym i rocznym?
- Które produkty i grupy klientów generują największe przychody?
- Jak kształtuje się marża zysku i średnia wartość zamówienia?

W obszarze kolizji drogowych zostały zbudowane wizualizacje odpowiadające na pytania:

- W których godzinach, dniach tygodnia i lokalizacjach Nowego Jorku dochodzi do największej liczby wypadków?
- Jakie czynniki najczęściej przyczyniają się do kolizji oraz ofiar śmiertelnych?
- Które dzielnice i ulice charakteryzują się najwyższym poziomem zagrożenia?

Odpowiedzi mają wspierać podejmowanie decyzji zarządczych, zarówno w zakresie optymalizacji działań sprzedażowych, jak i planowania działań na rzecz poprawy bezpieczeństwa ruchu drogowego.


3. Sprzedaż

3.1. Opis case study i założeń

Dane wykorzystane w projekcie sprzedażowym pochodzą z poprzedniego ćwiczenia i zostały zaimportowane do środowiska Microsoft Power BI jako zewnętrzne dane dotyczące działalności przedsiębiorstwa. Oryginalny zbiór zawierał 6 kolumn, z czego trzy: Product ID, Selling Price oraz Sales Revenue, posiadały znaczące braki danych. Produkty na przestrzeni lat miały różne ceny, zdecydowano się je ujednolicić. Ponadto zdecydowano się pominąć dane z lat 2002 i 2023, ponieważ były to niepełne okresy, przez co wykresy zawierające zagregowane dane wyraźnie odstawały od pozostałych. Dodatkowo zostały zasymulowane dane dotyczące kosztów produkcji oraz ocen zamówień.

3.2. Transformacja Danych w Power Query

Dane w formacie .xlsx zostały zaimportowane do programu za pomocą interfejsu programu (wstążka Data → Excel Workbook). Po wczytaniu pliku automatycznie wyświetlił się podgląd danych. W celu imputacji brakujących wartości oraz weryfikacji poprawności typów danych wybrano opcję Transform Data, która przenosi użytkownika do Power Query, gdzie możliwa jest transformacja danych.



Navigator

Arkusz2

Date	Product ID	Product Name	Selling Price	Sales Quantity	Customer ID	Sales Revenue
15.03.2023	119	Surf Gloves	20	5	843	100
15.03.2023	107	Beach Towel	20	8	85	160
05.04.2023	111	Board Shorts	50	3	439	null
22.03.2023	120	Noise Guard	8	2	849	null
22.03.2023	102	Wetsuit	150	6	47	null
02.04.2023	108	Sunglasses	80	1	667	null
02.04.2023	112	Surf T-Shirt	30	10	873	null
27.03.2023	105	Surf Wax	5	12	241	null
27.03.2023	129	Surf Sticker	2,5	4	637	null
08.04.2023	117	Surf Rack	100	7	535	null
08.04.2023	113	Beach Bag	15	9	182	null
18.03.2023	122	Surf Mat	25	15	205	null
18.03.2023	123	Surf Poncho	35	11	134	null
25.03.2023	109	Beach Umbrella	30	18	207	null
25.03.2023	126	Surf Journal	12	13	897	null
30.03.2023	124	Surf Tool	10	14	256	null
30.03.2023	110	Surf Leash	15	16	535	null
10.04.2023	101	Surfboard	500	19	598	null
10.04.2023	114	Bodyboard	60	17	426	null
20.03.2023	116	Surf Fins	40	20	183	null
20.03.2023	121	Surf Hoodie	70	3	780	null
03.04.2023	125	Surf DVD	7	5	327	null
03.04.2023	130	Surf Magazine	6	1	412	null
29.03.2023	115	Surf Hat	12	6	363	null

Load Transform Data Cancel

Plik Home Transform Add Column View Tools Help

Close & Apply Close New Source Recent Sources Enter Data Data source settings Data Sources Manage Parameters Parameters Export query results Output Data Refresh Preview Advanced Editor Query Choose Columns Remove Columns Manage Columns Keep Rows Remove Rows Reduce Rows Sort Split Column Group By Data Type: Date Use First Row as Headers Replace Values Transform Merge Queries Append Queries Combine Files Combine

Braki występowały w kolumnach *Product ID*, *Selling Price* oraz *Sales Revenue*. W celu imputacji wartości w pierwszych dwóch kolumnach tabela danych wejściowych została zduplikowana (prawy przycisk myszy → *Duplicate*), a następnie wykonano następujące operacje:

- pozostawienie kolumn *Product ID*, *Product Name* oraz *Selling Price* (prawy przycisk myszy na nagłówek kolumny → *Remove Other Columns*),
- deduplikacja wartości w kolumnie *Product Name* (prawy przycisk myszy na nagłówek → *Remove Duplicates*).
- dodanie wartości kosztu produktu

```
= Table.AddColumn(
    #"Removed Duplicates",
    "Product Cost",
    each [Selling Price] * (0.5 + Number.Random() * 0.3)
)
```

W wyniku tych operacji stworzona została tabela ze zmapowanymi wartościami zależnymi od *Product Name*.

	123 Product ID	A8C Product Name	1.2 Selling Price	ABC123 Product Cost
1	119	Surf Gloves	20	4,799981247
2	107	Beach Towel	20	4,799981247
3	111	Board Shorts	50	11,99995312
4	120	Nose Guard	8	1,919992499
5	102	Wetsuit	150	35,99985935
6	108	Sunglasses	80	19,19992499
7	112	Surf T-Shirt	30	7,199971871
8	105	Surf Wax	5	1,199995312
9	129	Surf Sticker	2,5	0,599997656
10	117	Surf Rack	100	23,99990624
11	113	Beach Bag	15	3,599985935
12	122	Surf Mat	25	5,999976559
13	123	Surf Poncho	35	8,399967182
14	109	Beach Umbrella	30	7,199971871
15	126	Surf Journal	12	2,879988748
16	124	Surf Tool	10	2,399990624
17	110	Surf Leash	15	3,599985935
18	101	Surfboard	500	119,9995312
19	114	Bodyboard	60	14,39994374
20	116	Surf Fins	40	9,59996249
21	121	Surf Hoodie	70	16,79993436
22	125	Surf DVD	7	1,679993436
23	130	Surf Magazine	6	1,439994374
24	115	Surf Hat	12	2,879988748
25	128	Surf Poster	15	3,599985935
26	127	Surf Calendar	9	2,159991561
27	104	Flip Flops	25	5,999976559
28	103	Sunscreen	10	2,399990624
29	118	Beach Chair	45	10,79995781
30	106	Rash Guard	40	9,59996249

Następnie powrócono do tabeli pierwotnej i w zakładce *Home* na wstążce, w sekcji *Combine*, wybrano opcję *Merge Queries*.

Merge

Select a table and matching columns to create a merged table.

Arkusz2

Date	Product ID	Product Name	Selling Price	Sales Quantity	Customer ID	Sales Revenue
15.03.2023	119	Surf Gloves	20	5	843	100
15.03.2023	107	Beach Towel	20	8	85	160
05.04.2023	111	Board Shorts	50	3	439	null
22.03.2023	120	Nose Guard	8	2	849	null
22.03.2023	102	Wetsuit	150	6	47	null

No preview is available

Join Kind

Left Outer (all from first, matching from second)

☐ Use fuzzy matching to perform the merge

▸ Fuzzy matching options


OK Cancel

W celu połączenia tabel w oknie dialogowym wskazano tabelę *mapping_table* oraz zaznaczono kolumnę *Product Name* jako klucz złączenia (odpowiednik klauzuli SQL *JOIN ON*).


Następnie usunięto kolumny *Product ID*, *Selling Price* oraz *Sales Revenue*, po czym za pomocą opcji *Custom Column* w zakładce *Add Column* utworzono je ponownie, pierwsze dwie jako kopie wartości z dołączonej tabeli mapującej, a ostatnia jako iloczyn dwóch poprzednich. Kolejnym krokiem było utworzenie kolumn czasowych: roku, miesiąca, nazwy miesiąca, kwartału oraz kolumny *yearmonth* łączącej rok i miesiąc.

Na koniec sprawdzono poprawność typów danych tzn. czy dane czasowe mają odpowiednie dane i konieczna była zamiana typu danych pieniężnych z intigera na zmiennoprzecinkowe.


W celu wzbogacenia analizy zostały zasymulowane dodatkowe kolumny. W Power Query została dodana kolumna *Customer Rating* zawierająca losowe oceny klientów w skali od 1 do 10, przy użyciu następującego wyrażenia:



Analogicznie zostały zasymulowane koszty produkcji, które posłużyły do obliczenia kwoty zysku, wartość zysku została wyznaczona poprzez odjęcie kosztu produkcji od przychodu ze sprzedaży (*Sales Revenue*), co umożliwiło zbudowanie miar takich jak marża zysku oraz miesięczny wynik finansowy na dashboardzie *Monthly Performance*.





Za pomocą opcji *Close & Apply* (zakładka *Home*, sekcja *Close*) zmiany zostały zapisane i wprowadzone do modelu danych.



3.3. Miary Dax

W projekcie zostały zbudowane miary DAX podzielone na cztery kategorie tematyczne.



Miary bazowe (KPI)

Podstawowe miary agregujące dane transakcyjne:

- **Total Sales:** całkowity przychód ze sprzedaży, obliczony jako suma kolumny *Sales Revenue*
- **Total Quantity:** łączna liczba sprzedanych jednostek produktów
- **Transactions:** liczba wierszy w tabeli, odpowiadająca liczbie zrealizowanych transakcji
- **Average Selling Price:** średnia cena sprzedaży produktów
- **Average Order Value:** średnia wartość zamówienia, obliczona jako iloraz *Total Sales* i liczby transakcji
- **Distinct Customers :** liczba unikalnych klientów
- **Distinct Products:** liczba unikalnych produktów

- **Sales per Customer:** średnia sprzedaż przypadająca na jednego klienta
- **Sales per Product:** średnia sprzedaż przypadająca na jeden produkt
- **Quantity per Transaction:** średnia liczba jednostek w pojedynczej transakcji

```

DEFINE
    // KPI / MIARY BAZOWE

    MEASURE 'data'[Total Sales] =
        SUM('data'[Sales Revenue])

    MEASURE 'data'[Total Quantity] =
        SUM('data'[Sales Quantity])

    MEASURE 'data'[Transactions] =
        COUNTROWS('data')

    MEASURE 'data'[Average Selling Price] =
        AVERAGE('data'[Selling Price])

    MEASURE 'data'[Average Order Value] =
        DIVIDE([Total Sales], [Transactions], 0)

    MEASURE 'data'[Distinct Customers] =
        DISTINCTCOUNT('data'[Customer ID])

    MEASURE 'data'[Distinct Products] =
        DISTINCTCOUNT('data'[Product ID])

    MEASURE 'data'[Sales per Customer] =
        DIVIDE([Total Sales], [Distinct Customers], 0)

    MEASURE 'data'[Sales per Product] =
        DIVIDE([Total Sales], [Distinct Products], 0)

    MEASURE 'data'[Quantity per Transaction] =
        DIVIDE([Total Quantity], [Transactions], 0)

```

Miara nowych klientów

Miara **New Customers** identyfikuje klientów, dla których pierwsza data zakupu (*FirstPurchaseDate*) mieści się w aktualnie wybranym zakresie dat.


```
// NOWI KLIENCI

Update model: Overwrite measure
MEASURE 'data'[New Customers] =
COUNTROWS(
    FILTER(
        ADDCOLUMNS(
            VALUES('data'[Customer ID]),
            "FirstPurchaseDate",
            CALCULATE(
                MIN('data'[Date]),
                ALL('data'[Date])
            )
        ),
        [FirstPurchaseDate] >= MIN('data'[Date]) &&
        [FirstPurchaseDate] <= MAX('data'[Date])
    )
)
```

Miary Czasowe

Miary analizy czasowej umożliwiające porównania okresu do okresu:

- **Sales Previous Month** i **Sales MoM %**: sprzedaż z poprzedniego miesiąca oraz zmiana miesięczna (Month over Month) wyrażona procentowo
- **Sales Previous Year** i **Sales YoY %**: sprzedaż z poprzedniego roku oraz zmiana roczna (Year over Year) wyrażona procentowo
- **Sales YTD**: narastająca sprzedaż od początku roku (*Year to Date*)
- **Sales MTD**: narastająca sprzedaż od początku miesiąca (*Month to Date*), obliczona funkcją TOTALMTD
- **Sales QTD**: narastająca sprzedaż od początku kwartału (*Quarter to Date*), obliczona funkcją TOTALQTD

```
// TIME INTELLIGENCE

MEASURE 'data'[Sales Previous Month] =
    CALCULATE(
        [Total Sales],
        DATEADD('data'[Date], -1, MONTH)
    )

MEASURE 'data'[Sales MoM %] =
    DIVIDE(
        [Total Sales] - [Sales Previous Month],
        [Sales Previous Month],
        0
    )

MEASURE 'data'[Sales Previous Year] =
    CALCULATE(
        [Total Sales],
        DATEADD('data'[Date], -1, YEAR)
    )

MEASURE 'data'[Sales YoY %] =
    DIVIDE(
        [Total Sales] - [Sales Previous Year],
        [Sales Previous Year],
        0
    )

MEASURE 'data'[Sales YTD] =
    TOTALYTD([Total Sales], 'data'[Date])

MEASURE 'data'[Sales MTD] =
    TOTALMTD([Total Sales], 'data'[Date])

MEASURE 'data'[Sales QTD] =
    TOTALQTD([Total Sales], 'data'[Date])
```

Dodatkowo została stworzona miara segmentująca klientów ze względu na liczbę zamówień. Liczba zamówień dla każdego klienta została wyznaczona poprzez zliczenie unikalnych kombinacji *Customer ID* i *Date* , co pozwala traktować każdy dzień zakupowy jako osobne zamówienie. Następnie, na podstawie obliczonej liczby zamówień, każdy klient został przypisany do jednej z czterech grup:

- **1–3 orders** – klienci o niskiej częstotliwości zakupów
- **4–5 orders** – klienci o umiarkowanej aktywności
- **6–10 orders** – klienci regularni
- **> 10 orders** – klienci o najwyższej częstotliwości zakupów

```

1 Customer Order Groups =
2 ADDCOLUMNS(
3     VALUES('data'[Customer ID]),
4     "Orders Count",
5     CALCULATE(
6         COUNTROWS(
7             SUMMARIZE(
8                 'data',
9                 'data'[Customer ID],
10                'data'[Date]
11            )
12        )
13    ),
14     "Order Group",
15     VAR OrdersCount =
16         CALCULATE(
17             COUNTROWS(
18                 SUMMARIZE(
19                     'data',
20                     'data'[Customer ID],
21                     'data'[Date]
22                 )
23             )
24         )
25     RETURN
26     SWITCH(
27         TRUE(),
28         OrdersCount >= 1 && OrdersCount <= 3, "1-3 orders",
29         OrdersCount >= 4 && OrdersCount <= 5, "4-5 orders",
30         OrdersCount >= 6 && OrdersCount <= 10, "6-10 orders",
31         OrdersCount > 10, "> 10 orders"
32     )
33 )

```

3.4. Model danych

Po zakończeniu transformacji danych został utworzony model danych w środowisku Power BI. Opierał się na relacjach pomiędzy tabelą główną zawierającą dane sprzedażowe (Data) oraz tabelami pomocniczymi (mapping_a oraz Customer Order Groups).

Tabela Data pełni rolę centralnej tabeli i zawiera informacje dotyczące transakcji sprzedażowych, klientów, produktów, dat oraz wartości finansowych, takich jak przychód i zysk.

Tabela mapping_a zawiera informacje dotyczące produktów, w tym:

- Product ID,
- Product Name,
- Product Cost.


Relacja pomiędzy tabelami mapping_a oraz Data została utworzona na podstawie kolumny Product Name w relacji typu jeden-do-wielu (1:*), co umożliwia poprawne przypisanie kosztów produktów do danych sprzedażowych.

Tabela **Customer Order Groups** zawiera informacje dotyczące segmentacji klientów według liczby zamówień. Relacja pomiędzy tabelami Customer Order Groups oraz Data została utworzona na podstawie kolumny Customer ID, również w relacji typu jeden-do-wielu (1:*).


Zastosowany model danych umożliwia:

- poprawne filtrowanie wizualizacji,
- dynamiczne działanie slicerów,


- analizę danych w różnych przekrojach,
- wykorzystanie funkcji drill-down,
- poprawne obliczanie miar DAX.



3.5. Dashboard 1: Sales Overview



Dashboard „Sales Overview” przedstawia ogólną sytuację sprzedażową przedsiębiorstwa w ujęciu wieloletnim.



1. Sekcja KPI

W górnej części dashboardu znajdują się najważniejsze wskaźniki KPI opisujące ogólną sytuację sprzedażową firmy.

Sekcja zawiera:

- **Total Quantity** : całkowita liczba sprzedanych produktów.

Mierzy sprzedaż niezależnie od wartości pieniężnej, pozwala to ocenić, czy wzrost przychodów wynika z wyższych cen, czy ze zwiększenia liczby sprzedanych sztuk.

- **Average Order Value**: średnia wartość zamówienia.

Spadek AOV przy rosnącej liczbie transakcji może sygnalizować przewagę drobnych, niskowartościowych zamówień.

- **Distinct Products**: liczba unikalnych produktów.

Pokazuje szerokość asortymentu.

- **Distinct Customers** : liczba unikalnych klientów.

Mierzy bazę klientów

Sekcja ta pozwala użytkownikowi szybko ocenić ogólną kondycję sprzedaży firmy.

35,14M

Total Sales

725K

Total Quantity

4,81K

Average Order Value

30

Distinct Products

1K

Distinct Customers

2. Total Sales by Year

Wykres liniowy przedstawia zmianę całkowitej sprzedaży w kolejnych latach. Pozwala analizować trendy sprzedażowe oraz identyfikować okresy wzrostów i spadków sprzedaży.

Wykres może być wykorzystany do:

- analizy długoterminowych trendów,
- wykrywania słabszych okresów sprzedaży,
- porównywania wyników pomiędzy latami.



Dashboard wykorzystuje również hierarchię dat w Power BI. Dzięki funkcjom:

Go to the next level in the hierarchy

oraz


Expand all down one level in the hierarchy



użytkownik może dynamicznie przechodzić pomiędzy różnymi poziomami szczegółowości danych, np.:

- rok → kwartał → miesiąc,
- rok → miesiąc.

Pozwala to analizować dane zarówno w ujęciu ogólnym, jak i bardziej szczegółowym. Możliwe jest przejście z wykresu prezentującego całkowitą sprzedaż według miesięcy do wykresu pokazującego sprzedaż dla wszystkich lat i miesięcy jednocześnie. Dzięki temu użytkownik może dokładniej analizować sezonowość oraz zmienność sprzedaży w czasie.



3. Total Sales by Product Name

Wykres kolumnowy przedstawia produkty generujące najwyższą wartość sprzedaży.

Pozwala:

- identyfikować najlepiej zarabiające produkty,
- wskazywać produkty o największym wpływie na przychody firmy.

Na wykresie można zauważyć, że niektóre produkty znacząco dominują pod względem wartości sprzedaży.



4. Distinct Customers by Year

Wykres liniowy pokazuje zmianę liczby klientów w kolejnych latach.

Pozwala analizować:

- rozwój bazy klientów,
- okresy wzrostu lub spadku zainteresowania ofertą firmy.

Wykres może być wykorzystany do oceny skuteczności działań marketingowych oraz utrzymania klientów.



5. Total Quantity by Product Name

Wykres przedstawia produkty sprzedawane w największej liczbie sztuk.

Pozwala:

- określić najczęściej kupowane produkty,
- porównywać popularność produktów,
- analizować różnice pomiędzy ilością sprzedaży a wartością sprzedaży.

Dzięki temu można sprawdzić, czy produkty generujące największą sprzedaż są jednocześnie najczęściej kupowane.



6. Sekcja Filtrów

W górnej części dashboardu znajdują się filtry:

- **Year,**
- **Quarter,**
- **Month,**
- **Product Name.**


Filtry umożliwiają dynamiczną analizę danych dla wybranego okresu lub produktu. Po zmianie filtrów wszystkie wizualizacje oraz KPI aktualizują się automatycznie.

Year	Quarter	Month	Product Name
All ▾	All ▾	🔍 ... ▾	All ▾

3.6. Dashboard 2: *Monthly Performance*



Dashboard „Monthly Performance” przedstawia miesięczne wyniki sprzedażowe oraz finansowe przedsiębiorstwa. Pozwala monitorować zmiany sprzedaży, zysków oraz marży w czasie, a także identyfikacji produktów generujących najwyższy wynik finansowy.



1. Sekcja KPI

W górnej części dashboardu znajdują się kluczowe wskaźniki efektywności sprzedaży dla wybranego okresu.

Sekcja zawiera:

- **Total Sales:** całkowita wartość sprzedaży,
- **Sales MTD:** sprzedaż Month-To-Date,
- **Sales QTD:** sprzedaż Quarter-To-Date,
- **Sales YTD :** sprzedaż Year-To-Date,
- **Sales MoM %:** procentowa zmiana sprzedaży miesiąc do miesiąca,

Umożliwiają menedżerowi śledzenie bieżącej realizacji planu sprzedażowego w dowolnym horyzoncie czasowym i szybką ocenę, czy firma jest na właściwej trajektorii.

- **Profit Margin %:** marża zysku.

Wzrost sprzedaży przy spadającej marży może oznaczać zbyt duże rabaty lub rosnące koszty produkcji.

Sekcja umożliwia szybkie monitorowanie bieżącej sytuacji sprzedażowej firmy oraz ocenę zmian sprzedaży i rentowności.

1,85M Total Sales	190,28K Sales MTD	585,17K Sales QTD	1,85M Sales YTD	0,11 Sales MoM %	74,63% Profit Margin %
-----------------------------	-----------------------------	-----------------------------	---------------------------	----------------------------	----------------------------------


2. Total Sales and Profit by Month

Wykres liniowy przedstawia miesięczną sprzedaż oraz zysk firmy.

Pozwala analizować zależność pomiędzy przychodami a osiąganym zyskiem w kolejnych miesiącach.

Wykres może być wykorzystany do:

- identyfikacji sezonowości sprzedaży,
- analizy miesięcy o najwyższej sprzedaży i zysku,
- porównania zmian sprzedaży względem zmian zysku.




3. Average of Customer Rating by Month

Wykres przedstawia średnią ocenę klientów w poszczególnych miesiącach.

Pozwala analizować:

- poziom satysfakcji klientów,
- zmiany ocen w czasie,
- zależność pomiędzy wynikami sprzedaży a ocenami klientów.

Może być wykorzystany do identyfikacji okresów, w których jakość obsługi lub produktów była oceniana lepiej lub gorzej.




4. Sum of Profit by Top 10 Products

Wykres słupkowy przedstawia produkty generujące najwyższy zysk.

Pozwala:

- identyfikować najbardziej rentowne produkty,
- analizować strukturę zysków,
- wskazywać produkty mające największy wpływ na wynik finansowy firmy.




5. Sekcja Filtrów


W górnej części dashboardu znajdują się filtry:

- **Year,**
- **Quarter,**
- **Month,**
- **Week of Year,**
- **Product Name.**

Filtry umożliwiają dynamiczną analizę danych dla wybranego okresu lub produktu. Zmiana wartości filtrów powoduje automatyczną aktualizację wszystkich KPI i wizualizacji znajdujących się na dashboardzie. Można np. wykluczyć Deskę surfingową jako produkt, który znacznie odbiega wynikiem od pozostałych.



3.7. Dashboard 3: Customer Analysis



Dashboard „Customer Analysis” koncentruje się na analizie klientów oraz ich aktywności zakupowej. Jego głównym celem jest identyfikacja struktury klientów, poziomu ich zaangażowania oraz ocena wartości generowanej przez grupy klientów.



1. Sekcja KPI


W górnej części dashboardu znajdują się podstawowe wskaźniki dotyczące klientów i zamówień.

Sekcja zawiera:

- **Sum of Orders Count:** całkowitą liczbę zamówień,
Pozwala ocenić ogólną aktywność zakupową klientów
- **Distinct Customers:** liczbę unikalnych klientów,
- **Average Sales per Customer :** średnią wartość sprzedaży przypadającą na jednego klienta.

Wzrost tego wskaźnika przy stałej liczbie klientów świadczy o skutecznych działaniach lojalnościowych i sprzedaży dodatkowe

Sekcja umożliwia szybką ocenę aktywności klientów oraz ich wpływu na sprzedaż firmy.




2. Average of Customer Rating

Wskaźnik przedstawia średnią ocenę klientów.

Pozwala:

- ocenić poziom satysfakcji klientów,
- monitorować jakość obsługi i produktów,
- szybko sprawdzić, czy średnia ocena klientów utrzymuje się na wysokim poziomie.

Wizualizacja umożliwia intuicyjne przedstawienie aktualnego poziomu ocen klientów względem maksymalnej wartości.




3. AOV by Group

Wykres kolumnowy przedstawia średnią wartość zamówienia (Average Order Value) dla poszczególnych grup klientów podzielonych według liczby zamówień.

Pozwala analizować:

- które grupy klientów generują najwyższą wartość zamówień,
- zależność pomiędzy aktywnością klientów a wartością zakupów,
- różnice pomiędzy klientami dokonującymi małej i dużej liczby zamówień.

Wykres może wspierać segmentację klientów oraz działania marketingowe.




4. Distinct Customers by Month

Wykres liniowy przedstawia liczbę unikalnych klientów w kolejnych miesiącach.

Pozwala:

- analizować zmiany liczby klientów w czasie,
- identyfikować miesiące o większej lub mniejszej aktywności klientów,

Wykres może być wykorzystany do oceny skuteczności kampanii marketingowych lub zmian zainteresowania ofertą firmy.




5. Distinct Customers by Order Group

Wykres pierścieniowy przedstawia udział klientów należących do poszczególnych grup zamówień.

Pozwala:

- analizować strukturę klientów,
- określić, jaka część klientów składa dużą liczbę zamówień,
- identyfikować dominujące grupy klientów.

Wizualizacja wspiera analizę segmentacji klientów oraz ocenę lojalności klientów.



6. Sekcja Filtrów

W górnej części dashboardu znajdują się filtry:

- **Year,**
- **Quarter,**

- **Month,**
- **Order Group.**

Filtry umożliwiają dynamiczną analizę danych dla wybranego okresu lub wybranej grupy klientów.

Year	Quarter	Month	Order Group
All	All	All	All

3.8. Testowanie i optymalizacja dashboardów

W trakcie realizacji projektu przeprowadzono testowanie poprawności działania dashboardów oraz interakcji pomiędzy wizualizacjami.

Sprawdzona została:

- poprawność działania filtrów i slicerów,
- poprawność aktualizacji miar KPI,
- działanie hierarchii dat oraz funkcji drill-down,
- zgodność wartości prezentowanych na wykresach z danymi źródłowymi.

Dodatkowo zoptymalizowano układ dashboardów pod względem czytelności i intuicyjności użytkowania.

Wszystkie wizualizacje na dashboardach są ze sobą interaktywne, wybór elementu na jednym wykresie powoduje filtrowanie pozostałych wizualizacji. Dodatkowo zmiana wartości filtrów powoduje automatyczną aktualizację wszystkich KPI i wizualizacji znajdujących się na dashboardzie.

Dashboard z zaznaczoną grupą (4-5 zamówień):

Customer Analysis

Year: All Quarter: All Month: All Order Group: All

882





Sum of Orders Count

194

Distinct Customers

21,23K

Average Sales per Customer



Dashboard dla lat 2021-2022 z wykluczeniem deski surfingowej z listy produktów:

Sales Overview

Year: Multiple sele... Quarter: All Month: All Product Name: Multiple sele...

2,25M

Total Sales

69K

Total Quantity

3,18K



Average Order Value

29

Distinct Products

496

Distinct Customers



4. Kolizje drogowe

4.1. Opis case study i założeń

Dane wykorzystane w projekcie dotyczącym kolizji drogowych zostały pobrane z publicznego zbioru danych „Motor Vehicle Collisions - Crashes” udostępnionego przez miasto Nowy Jork za pośrednictwem platformy NYC Open Data. Dane zostały pozyskane przy użyciu interfejsu API w zakresie lat 2019-2026 i obejmują informacje dotyczące lokalizacji kolizji, czasu zdarzenia, liczby ofiar, uczestników zdarzeń oraz czynników przyczyniających się do wypadków.

W projekcie przyjęto założenie, że analiza danych ma umożliwić identyfikację najbardziej niebezpiecznych lokalizacji, okresów zwiększonej liczby wypadków oraz najczęstszych przyczyn kolizji drogowych.

4.2. Pozyskanie danych

Dane zostały pobrane za pośrednictwem publicznego w języku Python z wykorzystaniem bibliotek requests oraz pandas a dane były pobierane partiami po 50 000 rekordów.

```
base_url = "https://data.cityofnewyork.us/resource/h9gi-nx95.csv"

all_data = []

for year in range(2019, 2026):

    offset = 0
    limit = 50000

    while True:
        query = (
            f"crash_date between "
            f"'{year}-01-01T00:00:00' and "
            f"'{year}-12-31T23:59:59'"
        )
        params = {
            "$where": query,
            "$limit": limit,
            "$offset": offset
        }

        response = requests.get(base_url, params=params)
        temp = pd.read_csv(StringIO(response.text))

        if temp.empty:
            break

        all_data.append(temp)
        print(f"{year} | offset {offset} | rows: {len(temp)}")

        offset += limit

df = pd.concat(all_data, ignore_index=True)

print(df.shape)
```

Na koniec dane zostały zapisane do formatu .csv w celu dalszej eksploracji i przekształcenia.

4.3. Eksploracyjna Analiza Danych i Tworzenie Cech

4.3.1. Braki Danych Przegląd

Po wczytaniu danych sprawdzone zostały typy danych oraz ich braki.

Kolumny dotyczące czwartego i piątego pojazdu (vehicle_type_code_4/5, contributing_factor_vehicle_4/5) charakteryzują się brakami przekraczającymi 97%, co oznacza, że większość kolizji dotyczy maksymalnie trzech pojazdów.

Kolumna	Typ danych	Braki [%]
vehicle_type_code_5	object	99,37
contributing_factor_vehicle_5	object	99,35
vehicle_type_code_4	object	97,90
contributing_factor_vehicle_4	object	97,79
vehicle_type_code_3	object	91,91
contributing_factor_vehicle_3	object	91,36
cross_street_name	object	73,22
off_street_name	object	50,50
zip_code	float64	32,16
borough	object	32,14
vehicle_type_code2	object	29,96
on_street_name	object	26,78
contributing_factor_vehicle_2	object	21,25
location	object	7,30
longitude	float64	7,30
latitude	float64	7,30
vehicle_type_code1	object	1,21
contributing_factor_vehicle_1	object	0,53
number_of_persons_injured	float64	<0,01
crash_date	object	0,00
crash_time	object	0,00
collision_id	int64	0,00
number_of_persons_killed	int64	0,00
number_of_pedestrians_injured	int64	0,00

number_of_pedestrians_killed	int64	0,00
number_of_cyclist_injured	int64	0,00
number_of_cyclist_killed	int64	0,00
number_of_motorist_injured	int64	0,00
number_of_motorist_killed	int64	0,00

Poziom braków dla większości kolumn jest równy dla lat 2019-2024, co sugeruje, że sposób zbierania danych nie uległ zmianom. Oznacza to, że wynikają z natury zdarzenia (np. brak czwartego pojazdu w kolizji) lub sposobu ich zbierania. W roku 2025 braki w kolumnach lokalizacyjnych (borough, zip_code) spadają do ~20%, podczas gdy w latach 2019-2024 wynosiły około 32-35%, analogiczne dla współrzędnych geograficznych (latitude, longitude), dla których braki spadają do ~1%, podczas gdy w latach poprzednich wynosiły około 7,5–8,6%. Może to świadczyć o wdrożeniu systemów GPS i automatycznej geolokalizacji przy rejestracji zdarzeń drogowych w 2025 roku.

4.3.2. Imputacja braków dzielnic metodą przestrzenną

Szczególnie ważna była imputacja braków danych dla kolumny **borough** (dzielnica), ponieważ dostarcza ona ważnych informacji przestrzennych, a jej uzupełnienie nie wymaga dużego obciążenia obliczeniowego. Do uzupełnienia braków została zastosowana imputacja przestrzenna oparta na złączeniu geometrycznym (*spatial join*).

Rekordy posiadające współrzędne geograficzne (latitude, longitude) ale pozbawione wartości borough, zostały przekształcone w obiekty punktowe przy użyciu biblioteki geopandas . Następnie wykonane zostało przestrzenne złączenie tych punktów z warstwą poligonową granic dzielnic Nowego Jorku (boroughs.geojson) przy użyciu within, który przypisuje każdy punkt do dzielnicy, w której się zawiera. Wartość dzielnicy odczytana z warstwy geometrycznej (BoroName) została wpisana jako uzupełnienie brakującej wartości w kolumnie borough.

```

# Testowa próbka 20 000 rekordów z istniejącym borough i GPS
test_borough_geo = (
    df[
        df["borough"].notna()
        & df["latitude"].notna()
        & df["longitude"].notna()
        & (df["latitude"] != 0)
        & (df["longitude"] != 0)
    ]
    .sample(20000, random_state=42)
    .copy()
)

test_borough_geo["original_borough"] = test_borough_geo["borough"]

# Zamiana punktów na GeoDataFrame
points_test = gpd.GeoDataFrame(
    test_borough_geo,
    geometry=gpd.points_from_xy(
        test_borough_geo["longitude"],
        test_borough_geo["latitude"]
    ),
    crs="EPSG:4326"
)

# Spatial join
joined_test = gpd.sjoin(
    points_test,
    boroughs[["BoroName", "geometry"]],
    how="left",
    predicate="within"
)

comparison_borough_geo = joined_test[
    [
        "latitude",
        "longitude",
        "original_borough",
        "BoroName"
    ]
].copy()

```

Przed imputacją wszystkich braków, została przeprowadzona próba na 20 000 rekordów, posiadających wartość dzielnicy. Która wykazała skuteczność na poziomie 99.84%.

```

Accuracy: 99.84%
is_correct
True      19968
False     32

```

W związku z tym metoda została zastosowana do pozostałych braków w kolumnie dzielnica. Dokonana została normalizacja wartości tekstowych w kolumnie borough, usunięte zostały zbędne spacje przy użyciu `.str.strip()`, a format wartości ujednolicony został do zapisu typu *Title Case* (pierwsza litera wielka, pozostałe małe).

```
df["borough"] = (
    df["borough"]
    .str.strip()
    .str.title()
)
```

Zabieg był niezbędny do poprawnego działania grupowania i filtrowania według dzielnic w Power BI, eliminując potencjalne duplikaty wynikające z różnic w wielkości liter lub dodatkowych spacji.

4.3.3. Transformacja i czyszczenie zbioru danych

Po przeprowadzeniu imputacji przestrzennej kolumny borough ze zbioru danych zostały usunięte rekordy, które nie posiadały żadnej informacji umożliwiającej identyfikację lokalizacji zdarzenia, brakowało im jednocześnie wartości zip_code, longitude, latitude oraz location. Rekordy te są nieprzydatne analitycznie w kontekście dashboardu przestrzennego. Usunięcie ich pozwoliło zachować spójność zbioru i uniknąć pustych punktów w wizualizacjach geograficznych.

Dodatkowo została usunięta kolumna location, która jest złożeniem kolumn **longitude** i **latitude** które będą bezpośrednio obsługiwane przez Power BI.

4.3.4. Feature Engineering: Python

Na podstawie surowych danych zostały zbudowane nowe zmienne, pogrupowane według obszaru tematycznego.

Zmienne czasowe

Na podstawie kolumn crash_date i crash_time zostały wyodrębnione szczegółowe informacje temporalne:

- year, month, month_name, day: rok, miesiąc i dzień zdarzenia
- day_of_week, day_of_week_number: nazwa i numer dnia tygodnia (0 = poniedziałek)
- quarter: kwartał roku
- week_of_year : numer tygodnia w roku według standardu ISO
- hour : godzina zdarzenia wyodrębniona z kolumny crash_time
- is_weekend: flaga logiczna przyjmująca wartość True dla soboty i niedzieli

- `time_of_day_6h`: pora dnia podzielona na cztery przedziały: *Night* (0-5), *Morning* (6-11), *Afternoon* (12-17), *Evening* (18-23)
- `is_rush_hour`: flaga logiczna oznaczająca godziny szczytu porannego (7-9) oraz popołudniowego (16-18)

```
df["quarter"] = df["crash_date"].dt.quarter
df["week_of_year"] = df["crash_date"].dt.isocalendar().week.astype("Int64")
df["is_rush_hour"] = df["hour"].between(7, 9) | df["hour"].between(16, 18)

df["total_injured"] = (
    df["number_of_persons_injured"].fillna(0)
    + df["number_of_pedestrians_injured"].fillna(0)
    + df["number_of_cyclist_injured"].fillna(0)
    + df["number_of_motorist_injured"].fillna(0)
)

df["total_killed"] = (
    df["number_of_persons_killed"].fillna(0)
    + df["number_of_pedestrians_killed"].fillna(0)
    + df["number_of_cyclist_killed"].fillna(0)
    + df["number_of_motorist_killed"].fillna(0)
)

df["has_injuries"] = df["total_injured"] > 0
df["has_fatalities"] = df["total_killed"] > 0

df["severity_level"] = np.select(
    [
        df["total_killed"] > 0,
        df["total_injured"] > 0
    ],
    [
        "Fatal",
        "Injury"
    ],
    default="Property Damage Only"
)
```

Zmienne dotyczące ofiar

Zostały zbudowane agregowane miary dotyczące liczby poszkodowanych, łączące dane ze wszystkich kategorii uczestników ruchu:

- `total_injured`: łączna liczba rannych, obliczona jako suma kolumn: `number_of_persons_injured`, `number_of_pedestrians_injured`, `number_of_cyclist_injured`, `number_of_motorist_injured`
- `total_killed`: łączna liczba ofiar śmiertelnych, obliczona analogicznie dla kolumn *_killed
- `has_injuries`: flaga logiczna przyjmująca wartość True, gdy `total_injured > 0`
- `has_fatalities`: flaga logiczna przyjmująca wartość True, gdy `total_killed > 0`

```

df["quarter"] = df["crash_date"].dt.quarter
df["week_of_year"] = df["crash_date"].dt.isocalendar().week.astype("Int64")
df["is_rush_hour"] = df["hour"].between(7, 9) | df["hour"].between(16, 18)

df["total_injured"] = (
    df["number_of_persons_injured"].fillna(0)
    + df["number_of_pedestrians_injured"].fillna(0)
    + df["number_of_cyclist_injured"].fillna(0)
    + df["number_of_motorist_injured"].fillna(0)
)

df["total_killed"] = (
    df["number_of_persons_killed"].fillna(0)
    + df["number_of_pedestrians_killed"].fillna(0)
    + df["number_of_cyclist_killed"].fillna(0)
    + df["number_of_motorist_killed"].fillna(0)
)

df["has_injuries"] = df["total_injured"] > 0
df["has_fatalities"] = df["total_killed"] > 0

```

Poziom ciężkości zdarzenia

Została zbudowana zmienna kategoryczna `severity_level` klasyfikująca każdą kolizję do jednej z trzech kategorii przy użyciu np. `select()`:

- **Fatal:** kolizja z co najmniej jedną ofiarą śmiertelną (`total_killed > 0`)
- **Injury :** kolizja z rannymi, bez ofiar śmiertelnych (`total_injured > 0`)
- **Property Damage Only :** kolizja bez poszkodowanych osób (wartość domyślna)

```

df["severity_level"] = np.select(
    [
        df["total_killed"] > 0,
        df["total_injured"] > 0
    ],
    [
        "Fatal",
        "Injury"
    ],
    default="Property Damage Only"
)

```

Agregacje analityczne

Na podstawie przetworzonych danych zostały zbudowane pomocnicze zestawienia analityczne:

- `crashes_by_year`: liczba kolizji w rozbiciu na lata
- `crashes_by_month`: liczba kolizji w rozbiciu na miesiące
- `crashes_by_weekday`: liczba kolizji według dnia tygodnia

- `crashes_by_hour`: liczba kolizji według godziny doby
- `crashes_by_rush_hour_year`: porównanie liczby kolizji w godzinach szczytu i poza nimi, z normalizacją przez liczbę godzin w danej kategorii (`crashes_per_hour`) oraz udziałem procentowym w rocznej liczbie zdarzeń
- `crashes_by_weekend_year`: analogiczne porównanie dla dni roboczych i weekendów, z normalizacją przez liczbę dni (`crashes_per_day`) oraz udziałem procentowym
- `borough_fatalities`: ranking dzielnic według łącznej liczby ofiar śmiertelnych

```
crashes_by_month = (
    df.groupby("month_name")
      .size()
      .reset_index(name="crashes")
)


display(crashes_by_month)
```

4.3.5. Feature Engineering: DAX

Już po załadowaniu danych do Microsoft Power B zostały stworzone dodatkowe miary:

- Avg Collisions per Day : średnia liczba kolizji przypadająca na jeden dzień.
- Avg Injured per Crash :średnia liczba rannych na jedną kolizję.
- Avg Killed per Crash: średnia liczba ofiar śmiertelnych na jedną kolizję.
- Fatal Crashes: liczba kolizji zaklasyfikowanych jako śmiertelne.
- Fatal Rate % : udział kolizji śmiertelnych w ogólnej liczbie kolizji.
- Injury Crashes: liczba kolizji z osobami rannymi.
- Property Damage Only : liczba kolizji bez osób poszkodowanych.
- Rush Hour Collisions: liczba kolizji w godzinach szczytu.
- Rush Hour Share % : udział kolizji w godzinach szczytu.
- Weekend Collisions : liczba kolizji w weekendy.
- Weekend Share % : udział kolizji weekendowych.
- Collisions YTD: narastająca liczba kolizji od początku roku.
- Collisions YoY %: procentowa zmiana liczby kolizji rok do roku.
- Top Contributing Factor : najczęściej występujący czynnik przyczyniający się do kolizji.

- Multi Vehicle Share % – udział kolizji wielopojazdowych.
- Pedestrian Fatal Rate % – udział ofiar śmiertelnych pieszych,
- Cyclist Fatal Rate % – udział ofiar śmiertelnych rowerzystów,
- Motorist Fatal Rate % – udział ofiar śmiertelnych kierowców i pasażerów pojazdów.



```

1  DEFINE
2  VAR PreviousYear2 =
3  RETURN
4  DIVIDE(CurrentYear - PreviousYear2, PreviousYear2, 0)
5
6  // UCZESTNICZY RUCHU
7
8  MEASURE nyc_collisions_clean[Pedestrian Injured] =
9  SUM(nyc_collisions_clean[number_of_pedestrians_injured])
10
11 MEASURE nyc_collisions_clean[Pedestrian Killed] =
12 SUM(nyc_collisions_clean[number_of_pedestrians_killed])
13
14 MEASURE nyc_collisions_clean[Cyclist Injured] =
15 SUM(nyc_collisions_clean[number_of_cyclist_injured])
16
17 MEASURE nyc_collisions_clean[Cyclist Killed] =
18 SUM(nyc_collisions_clean[number_of_cyclist_killed])
19
20 MEASURE nyc_collisions_clean[Motorist Injured] =
21 SUM(nyc_collisions_clean[number_of_motorist_injured])
22
23 MEASURE nyc_collisions_clean[Motorist Killed] =
24 SUM(nyc_collisions_clean[number_of_motorist_killed])
25
26 MEASURE nyc_collisions_clean[Pedestrian Fatal Rate %] =
27 DIVIDE([Pedestrian Killed], [Total Killed], 0)
28
29 MEASURE nyc_collisions_clean[Cyclist Fatal Rate %] =
30 DIVIDE([Cyclist Killed], [Total Killed], 0)
31
32 MEASURE nyc_collisions_clean[Motorist Fatal Rate %] =
33 DIVIDE([Motorist Killed], [Total Killed], 0)
34
35 // DODATKOWE METRYKI

```

4.3.6. Ujednolicenie nazw ulic w Power Query

Nazwy ulic wymagały dodatkowego ujednolicenia, ponieważ w danych występowały różne warianty zapisu tych samych typów ulic. Część nazw była zapisana skrótowo, np. AVE zamiast AVENUE, ST zamiast STREET, RD zamiast ROAD. Dodatkowo część ulic numerowanych posiadała sufiksy porządkowe, np. TH, ST, ND, RD, a część była zapisana bez nich.



109 ST
109 STREET
10th ave
10TH AVENUE
11 AVE
11 AVENUE
11 PL
11 PLACE
11 ST
11 STREET
110 AVE
110 AVENUE
...

Ponieważ problem został zauważony dopiero na etapie pracy w Power BI, czyszczenie nazw ulic wykonano w **Power Query** poprzez utworzenie nowej kolumny Street Name.

W pierwszym kroku nazwa ulicy została:

- zamieniona na wielkie litery,
- oczyszczona ze zbędnych spacji,
- rozdzielona na część numeryczną oraz pozostałą część nazwy.

Następnie dla ulic rozpoczynających się od numeru dodano odpowiedni sufix:

- ST dla liczb kończących się na 1,
- ND dla liczb kończących się na 2,
- RD dla liczb kończących się na 3,
- TH dla pozostałych przypadków oraz wyjątków 11, 12 i 13.

Ostatecznie ujednolicone zostały skróty typów ulic, m.in.:

- AVE, AVENUE,
- ST, STREET,
- RD, ROAD,
- PL, PLACE,
- BLVD, BOULEVARD,
- DR, DRIVE.

Dzięki temu wartości takie jak 109 AVE, 109 AVENUE oraz 109TH AVE mogły zostać sprowadzone do spójnej formy. Ujednolicona kolumna została wykorzystana później w dashboardzie do analizy ulic z największą liczbą kolizji.


4.3.7. Wizualizacje eksploracyjne i mapa hotspotów

Przed przystąpieniem do tworzenia dashboardów w Power BI zostały przygotowane wstępne wizualizacje eksploracyjne w środowisku Python. Jedną z kluczowych wizualizacji była interaktywna mapa hotspotów śmiertelnych kolizji w Nowym Jorku. W pierwszym kroku dane zostały zagregowane według unikalnych kombinacji współrzędnych geograficznych (latitude, longitude), a dla każdej lokalizacji obliczono


sumaryczną liczbę ofiar śmiertelnych (total_killed). Następnie zastosowano filtr uwzględniający lokalizacje, w których łączna liczba zabitych przekraczała 2:

```
fatal_hotspots = (  
    spatial_df  
    .groupby(["latitude", "longitude"])["total_killed"]  
    .sum()  
    .reset_index()  
)  
  
fatal_hotspots = fatal_hotspots[  
    fatal_hotspots["total_killed"] > 2  
)  
  
fatal_hotspots = fatal_hotspots.sort_values(  
    "total_killed",  
    ascending=False  
)
```


Fatal Crash Hotspots in NYC



4.4. Dashboard 1: New York City Collision & Fatality Analysis



Dashboard przedstawia analizę kolizji drogowych oraz ofiar wypadków w Nowym Jorku z uwzględnieniem trendów czasowych, godzin szczytu oraz najniebezpieczniejszych czynników kolizji.



1. Sekcja KPI

W górnej części dashboardu znajdują się kluczowe wskaźniki dotyczące kolizji drogowych oraz ich skutków.

Sekcja zawiera:

- **Total Collisions** : całkowitą liczbę kolizji,
- **Total Injured**: całkowitą liczbę osób rannych,
- **Total Killed**; całkowitą liczbę ofiar śmiertelnych,

Ich analiza w podziale na dzielnice, godziny pozwalają identyfikować sytuacje o ryzyku i priorytetyzować działania służb miejskich.

- **Rush Hour Crashes per Hour**: średnią liczbę kolizji na godzinę w godzinach szczytu,
- **Normal Hours Crashes per Hour**: średnią liczbę kolizji poza godzinami szczytu.

Wskaźniki normalizują liczbę kolizji przez czas trwania danego przedziału, umożliwiając rzetelne porównanie intensywności zdarzeń między godzinami szczytu a pozostałą częścią doby.

Sekcja umożliwia szybką ocenę skali kolizji drogowych oraz porównanie intensywności zdarzeń w godzinach szczytu i poza nimi.



2. Crash Metrics

Wykres liniowy przedstawia zmiany liczby kolizji, rannych oraz ofiar śmiertelnych w czasie.


Pozwala:

- analizować trendy kolizji w kolejnych latach,
- porównywać zmiany liczby rannych i ofiar śmiertelnych,
- identyfikować okresy wzrostów i spadków liczby zdarzeń.

Dashboard wykorzystuje również dynamiczne przełączanie metryk przy pomocy przycisków:

- **Total Collisions**,
- **Total Injured**,
- **Total Killed**.

Dzięki temu użytkownik może szybko zmieniać analizowaną kategorię danych.



3. Średnie dzienne wartości


Sekcja zawiera trzy wykresy liniowe:

- **Average Daily Collisions:** średnia dzienna liczba kolizji,
- **Average Daily Injuries:** średnia dzienna liczba rannych,
- **Average Daily Fatalities:** średnia dzienna liczba ofiar śmiertelnych.

Pozwala:

- analizować średnią intensywność zdarzeń w czasie,
- obserwować zmiany liczby rannych i ofiar śmiertelnych,
- porównywać trendy pomiędzy różnymi kategoriami zdarzeń.

Wizualizacje pomagają identyfikować okresy zwiększonego ryzyka na drogach.



4. Top 10 Most Dangerous Collision Factors

Sekcja przedstawia ranking najbardziej niebezpiecznych czynników powodujących kolizje drogowe.


Wizualizacja wykorzystuje dynamiczny wybór typu wskaźnika:

- **Overall,**
- **Cyclist,**
- **Motorist,**
- **Pedestrian.**

Pozwala:

- identyfikować najgroźniejsze przyczyny kolizji,
- analizować różnice pomiędzy grupami uczestników ruchu,
- oceniać wpływ poszczególnych czynników na bezpieczeństwo drogowe.

Sekcja może wspierać analizę ryzyka oraz działania związane z poprawą bezpieczeństwa ruchu drogowego.



5. Collisions by Day of Week and Time of Day

Tabela heatmap przedstawia liczbę kolizji według dnia tygodnia oraz pory dnia:

- Morning,
- Afternoon,
- Evening,
- Night.

Pozwala:

- analizować rozkład kolizji w ciągu tygodnia,

- identyfikować najbardziej niebezpieczne pory dnia,
- porównywać intensywność zdarzeń pomiędzy dniami roboczymi i weekendami.

Kolorystyka heatmapy umożliwia szybkie wskazanie okresów o największej liczbie zdarzeń drogowych.

Collisions by Day of Week and Time of Day

Day of week	Morning	Afternoon	Evening	Night
Monday	30776	39650	24535	12524
Tuesday	32312	41181	26531	9603
Wednesday	30180	41150	27402	10150
Thursday	31253	41291	27934	10817
Friday	30617	43814	32169	12712
Saturday	20375	34608	30064	20569
Sunday	16845	30765	25797	22469

Morning (6 AM – 12 PM) Afternoon (12 PM – 6 PM)
 Evening (6 PM – 12 AM) Night (12 AM – 6 AM)

Na heatmapie można zauważyć, że mimo iż godziny nocne są ogólnie wyraźnie mniej kolizyjne niż pozostałe pory dnia, to noce weekendowe, charakteryzują się znacznie większą liczbą zdarzeń niż noce w dni robocze. W niektórych przypadkach liczba nocnych kolizji w weekendy jest nawet ponad dwukrotnie wyższa niż w środku tygodnia, co może wskazywać na zwiększony ruch nocny, aktywność rozrywkową oraz większe ryzyko niebezpiecznych zachowań kierowców w weekendy.

6. Sekcja filtrów

W górnej części dashboardu znajdują się filtry:

- **Year,**
- **Is weekend,**
- **Borough.**

Filtry umożliwiają dynamiczną analizę danych dla wybranego okresu, rodzaju dnia oraz dzielnicy Nowego Jorku.

Zmiana wartości filtrów powoduje automatyczną aktualizację wszystkich KPI i wizualizacji znajdujących się na dashboardzie.

Year

All
▼


Is weekend

All
▼


Borough

All
▼

4.5. Dashboard 2: New York City Hotspots & Spatial Analysis



Dashboard koncentruje się na analizie przestrzennej kolizji drogowych w Nowym Jorku oraz identyfikacji najbardziej niebezpiecznych lokalizacji i obszarów o zwiększonym ryzyku występowania śmiertelnych zdarzeń. Dzięki wykorzystaniu map, rankingów ulic oraz analiz dzielnic dashboard umożliwia szybkie wykrywanie hotspotów kolizji oraz analizę rozmieszczenia zdarzeń w przestrzeni miejskiej.




1. Total Collisions by Borough

Wykres słupkowy przedstawia liczbę kolizji w poszczególnych dzielnicach Nowego Jorku:

- **Brooklyn,**
- **Queens,**
- **Manhattan,**
- **Bronx,**
- **Staten Island.**

Pozwala:

- porównywać liczbę kolizji pomiędzy dzielnicami,
- identyfikować obszary o największej liczbie zdarzeń drogowych,
- analizować przestrzenny rozkład kolizji w mieście.



2. Most Dangerous Streets in NYC

Tabela przedstawia najbardziej niebezpieczne ulice w Nowym Jorku wraz z:

- liczbą kolizji,
- liczbą rannych,
- liczbą ofiar śmiertelnych.

Pozwala:

- identyfikować najbardziej problematyczne ulice,
- analizować zależność pomiędzy liczbą kolizji a liczbą ofiar,
- wskazywać lokalizacje wymagające poprawy bezpieczeństwa ruchu drogowego.

Nazwy ulic zostały wcześniej ujednolicone w Power Query w celu usunięcia niespójności zapisów.

Most Dangerous Streets in NYC

Street Name	Total Collisions	Total Injured	Total Killed
MAJOR DEEGAN EXPRESSWAY	4800	5987	48
LONG ISLAND EXPRESSWAY	7542	8618	44
GRAND CENTRAL PKWY	6180	7671	42
FDR DRIVE	5587	5828	32
CROSS ISLAND PARKWAY	4544	4990	26
BROOKLYN QUEENS EXPRESSWAY	7052	8309	30
BROADWAY	6623	6481	34
BELT PARKWAY	10932	13939	96
ATLANTIC AVENUE	4997	5070	40

3. Fatal Crash Hotspots

Mapa przedstawia hotspoty śmiertelnych kolizji drogowych.

Wizualizacja stanowi próbę odwzorowania wcześniejszej analizy przestrzennej wykonanej w Pythonie.

W celu grupowania lokalizacji zostały utworzone pomocnicze miary:

- `latitude_hotspot = ROUND(latitude, 2)`,
- `longitude_hotspot = ROUND(longitude, 2)`.


Zaokrąglenie współrzędnych pozwoliło agregować pobliskie zdarzenia do wspólnych obszarów hotspotów. Dzięki temu możliwe było lepsze zobrazowanie skupisk śmiertelnych kolizji w przestrzeni miejskiej.

Mapa umożliwia:


- identyfikację obszarów o podwyższonym ryzyku,
- analizę przestrzennego rozmieszczenia śmiertelnych zdarzeń,
- szybkie wskazanie lokalizacji wymagających poprawy bezpieczeństwa.

Kliknięcie hotspotu powoduje dodatkowo interakcję z sąsiednią mapą i pozwala zobaczyć wybrany obszar w szerszym kontekście przestrzennym.

Fatal Crash Hotspots



Total Collisions




4. Total Collisions

Mapa przedstawia przestrzenny rozkład wszystkich kolizji drogowych w Nowym Jorku.

Pozwala:

- analizować koncentrację zdarzeń drogowych,
- obserwować rozkład kolizji w różnych częściach miasta,
- porównywać obszary o większym i mniejszym natężeniu zdarzeń.

Mapa współpracuje z wizualizacją hotspotów i umożliwia bardziej szczegółową analizę przestrzenną wybranych lokalizacji.



5. Sekcja filtrów

W górnej części dashboardu znajdują się filtry:

- **Year,**
- **Month,**
- **Is weekend,**
- **Is rush hour.**

Filtry umożliwiają dynamiczną analizę danych dla wybranego okresu oraz rodzaju dnia i godzin ruchu. Zmiana wartości filtrów powoduje automatyczną aktualizację wszystkich wizualizacji znajdujących się na dashboardzie.

Year	Month	Is weekend	Is rush hour
All ▼	All ▼	All ▼	All ▼

4.6. Wnioski z analizy kolizji drogowych w Nowym Jorku

Dashboards pozwalają spojrzeć na bezpieczeństwo drogowe w Nowym Jorku z trzech perspektyw:

- czasowej,
- przyczynowej
- przestrzennej.

Dane czasowe pokazują, że kolizje nie rozkładają się równomiernie w ciągu doby ani tygodnia. Godziny szczytu komunikacyjnego charakteryzują się wyraźnie wyższą intensywnością zdarzeń niż pozostałe pory dnia. Noce weekendowe generują ponad dwukrotnie więcej zdarzeń niż noce w dni robocze, co może świadczyć o wpływie ncnego życia na zachowania bądź stan kierowców.

Możliwość analizy **przyczynowej** czynników kolizji, pozwala na rozróżnienie źródeł zagrożeń dla różnych grup:

- pieszych,
- rowerzystów,
- kierowców.

Przestrzenna mapa hotspotów i ranking ulic wskazują lokalizacje o najwyższej koncentracji śmiertelnych zdarzeń, a zestawienie z liczbą kolizji według dzielnic pozwala ocenić, gdzie problem jest najbardziej nasilony. Takie informacje mogą wspierać działania oraz inwestycje prewencyjne.

Połączone dashboards tworzą narzędzie, które może wspierać lokalną władzę, służby miejskie w podejmowaniu decyzji mających poprawić bezpieczeństwo na drogach Nowego Jorku.

5. Podsumowanie

Projekt obejmował budowę pięciu interaktywnych dashboardów w Microsoft Power BI w dwóch obszarach tematycznych: analizie sprzedaży oraz analizie kolizji drogowych na terenie Nowego Jorku.

Projekt pokazuje, że poprawna wizualizacja skutecznie pełni rolę narzędzia wspierającego analizę danych oraz proces podejmowania decyzji biznesowych i analitycznych.

Należy jednak pamiętać, że kluczowym etapem całego procesu pozostaje preprocessing danych, obejmujący ich czyszczenie, transformację, imputację braków danych oraz tworzenie nowych cech. W zależności od środowiska pracy, jakości danych źródłowych oraz skali i złożoności zbioru danych proces ten może być czasochłonny oraz wymagać znacznych zasobów obliczeniowych i analitycznych. Dopiero odpowiednio przygotowane dane pozwalają na budowę poprawnych modeli danych, wiarygodnych wskaźników KPI oraz wartościowych wizualizacji. Istotnym aspektem jest aktualność danych, raporty oparte na

nieaktualnych danych mogą prowadzić do błędnych wniosków i decyzji. W celu zapewnienia ciągłości danych warto rozważyć budowę pipeline'u obejmującego cykliczne pobieranie danych ze źródeł, ich czyszczenie i transformację oraz przesyłanie do Power BI.

W pracy wykorzystano narzędzia generatywnego AI w celu poprawy językowej stylistycznej oraz pracy z językiem DAX